

DEFINIZIONE

UN PROGRAMMA IMPARA DA UN'ESPERIENZA E RISPETTO A DUE CLASSI DI COMPITI T E MISURE DI PERFORMANCE P , QUANDO LE SUE PERFORMANCE NELLE TASKS IN T MISURATE DA P , MIGLIORANO CON ESPERIENZA E .

DEFINIZIONE PER UN AGENTE CHE IMPARA:

- TASK T
- MISURAZIONE PERFORMANCE P
- ESPERIENZA E

INDUCTIVE LEARNING

CON QUESTA TECNICA CERCHIAMO DI ESTRAIRE UNA REGOLA / MODELLO GENERALE DA UN INSIEME DI DATI OSSERVATI, AL FINE DI GENERALIZZARE.

INPUT → UN INSIEME DI DATI DI ADDESTRAMENTO CHE CONSISTE IN COPPIE DI INPUT & OUTPUT (x_i, y_i) :

- x_i RAPPRESENTA LE CARATTERISTICHE (FEATURES) DI UN ESEMPIO
- y_i RAPPRESENTA L'ETICHETTA (OUTPUT o TARGET)

CARATTERISTICHE		TARGET	
Altezza (cm)	Peso (kg)	Piume	Etichetta
50	0.8	Sì	Uccello
150	50	No	Mammifero
55	1.0	Sì	Uccello

ESEMPIO

OUTPUT → MODELLO o FUNZIONE $f(x)$ CHE PUÒ PREDIRE y PER NUOVI ESEMPI NON ANCORA OSSERVATI. Es.

"SE L'ANIMALE HA LE PIUME ALLORA È UN UCCELLO"

"SE NON HA PIUME E PESA PIÙ DI 10 KG ALLORA È UN MAMMIFERO"

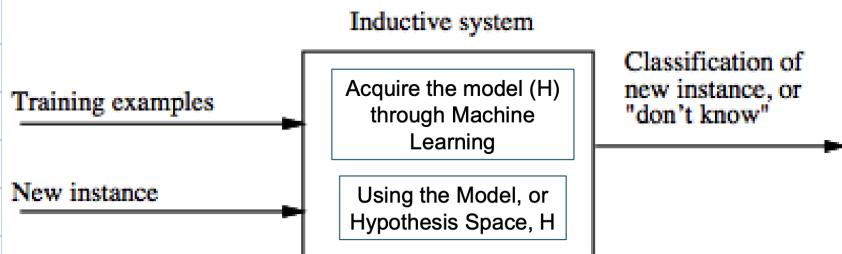
OBIETTIVO → IDENTIFICARE UNA FUNZIONE f CHE APPROSSIMI LA RELAZIONE TRA GLI INPUT & OUTPUT OSSERVATI NEL SET DI DATI.

COSÌ DA GENERALIZZARE A DATI NON VISTI.

$$X_{\text{nuovo}} = \{ \text{ALT: } 60 \text{ cm, PESO: } 1,2 \text{ kg, PIUME: Sì} \} \xrightarrow{\text{PREDIZIONE}} \text{UCCELLO}$$

INDICHiamo CON h LA FUNZIONE CHE IL NOSTRO ALGORITMO APPRENDE BASANDOSI SUGLI ESEMPI FORNITI. NON POSSIAMO CONOSCERE LA f REALE OVVERO LA FUNZIONE TARGET, QUINDI CERCHIAMO UNA FUNZIONE h CHE LA APPROSSIMI.
VOGLIAMO QUINDI MINIMIZZARE LA DIFFERENZA TRA $h(x)$ e $f(x)$. $\rightarrow h \approx f$

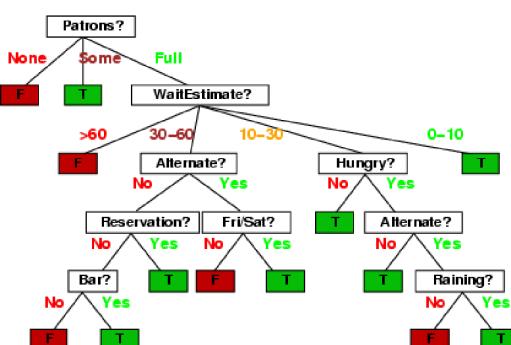
SISTEMA



ALBERI DI DECISIONE

STRUTTURA AD ALBERO IN CUI OGNI NODO INTERNO RAPPRESENTA UNA DECISIONE BASATA SU UNA CARATTERISTICA DEI DATI, OGNI RAMO RAPPRESENTA UN ESITO POSSIBILE DI QUELLA DECISIONE. OGNI FOGLIA RAPPRESENTA UNA PREDIZIONE FINALE.

ESEMPIO SE DOBBIAMO DECIDERE DI ASPETTARE AL RISTORANTE:



SPAZIO DELLE IPOTESI

QUANTI ALBERI DIVERSI POSSONO ESSERCI CON m ATTRIBUTI BOOLEANI

$m = 2$, OGNI ATTRIBUTO PUÒ ESSERE V o F, NUMERO DI POSSIBILI COMBINAZIONI ABBIAMO QUINDI 4 COMBINAZIONI DI INPUT NELLA TABELLA DI VERITÀ. AVENDO QUESTE 4 COMBINAZIONI POSSIAMO AVERE 2^{2^m} POSSIBILI OUTPUT

DATO CHE OGNI RIGA PUÒ AVERE V o F:

A B

0 0	0 1 0 1 1 0 1 0 0 1 0 1 0 1 0 1
0 1	0 1 1 0 0 1 1 0 1 0 0 1 1 0 0 1
1 0	0 1 1 0 1 0 0 1 1 0 1 0 0 1 0 1
1 1	0 1 0 1 0 1 0 1 1 0 0 1 0 1 1 0

QUANTE IPOTESI CONGIUNTIVE POSSONO ESSERCI?

IPOTESI CONGIUNTIVA, COMBINA LE CONDIZIONI TRAMITE L'OPERAZIONE LOGICO AND. OGNI ATTRIBUTO PUÒ ESSERE:

- INCLUSO (es. A)
- INCLUSO NEGATIVAMENTE ($\neg A$)
- ESCLUSO DALLA FORMULA (NON COMPARE)

QUINDI OGNI ATTRIBUTO PUÒ ASSUMERE 3 STATI, IL NUMERO TOTALE DI IPOTESI CONGIUNTIVE È 3^m

ESEMPIO CON 2 ATTRIBUTI (A, B QUINDI $3^2 = 9$)

$(A \wedge B) (\neg A \wedge \neg B) (A \wedge \neg B) (\neg A \wedge B) (A) (B) (\neg A) (\neg B) ()$ } 9 CONGIUNZIONI

- **Pro:** Aumenta la probabilità di trovare una funzione che descrive perfettamente la relazione tra input e output (la "target function").
- **Contro:** Aumenta il rischio di scegliere una funzione che si adatta ai dati di addestramento, ma non generalizza bene ai dati non visti (**overfitting**).

DTL (DECISION TREE LEARNING)

```
function DTL(examples, attributes, default) returns a decision tree
  if examples is empty then return default ①
  else if all examples have the same classification then return the classification ②
  else if attributes is empty then return MODE(examples) ③
  else ④
    best ← CHOOSE-ATTRIBUTE(attributes, examples)
    tree ← a new decision tree with root test best
    for each value  $v_i$  of best do
      examples $_i$  ← {elements of examples with best =  $v_i$ }
      subtree ← DTL(examples $_i$ , attributes - best, MODE(examples))
      add a branch to tree with label  $v_i$  and subtree subtree
  ⑤ return tree
```

SET DI DATI

Outlook	Humidity	Windy	Play
Sunny	High	False	No
Sunny	High	True	No
Sunny	Normal	False	Yes
Rainy	High	False	Yes
Rainy	Normal	True	No

↓
VALORE ATTRIBUTO

→ ESEMPIO (RIGA)
TARGET / ETICHETTA
} ESEMPI

① SE EXAMPLES È VUOTO

SE NON CI SONO ESEMPI DA ANALIZZARE ALLORA VIENE RITORNATO IL VALORE DI DEFAULT FORNITO.

② SE TUTTI GLI ESEMPI HANNO LA STESSA CLASSIFICAZIONE

SE TUTTI GLI ESEMPI APPARTENGONO ALLA STESSA CLASSE (g. TUTTI POSITIVI o NEG.), LA FUNZIONE RESTITUISCE QUESTA CLASSIFICAZ. COME FOGLIA DELL'ALBERO. ES.

Outlook	Humidity	Windy	Play
Sunny	High	False	YES
Sunny	High	True	YES
Sunny	Normal	False	Yes
Rainy	High	False	Yes
Rainy	Normal	True	No

ALBERO DECISIONALE → PLAY = YES

③ ATTRIBUTI ESAURITI

SE NON CI SONO ATTRIBUTI PER DIVIDERE I DATI LA FUNZ. RESTITUISCE LA CLASSIFICAZIONE PIÙ COMUNE TRA GLI ESEMPI RIMANENTI.

④ CASO GENERALE, SCELTA ATTRIBUTO MIGLIOR

L'ALGORITMO SELEZIONA L'ATTRIBUTO PIÙ SIGNIFICATIVO PER DIVIDERE I DATI, UTILIZZANDO UN CRITERIO COME L'ENTROPIA o GUADAGNO INFORMATIVO. QUESTO ATTR. SCELTO VIENE CHIAMATO **BEST** NELLO PSEUDOCODICE.

VIENE CREATO UN NODO RADICE PER L'ALBERO CON **ROOT = BEST**

⑤ DIVISIONE RICORSIVA DEI DATI

PER CIASUN ^{*}VALORE DELL' ATTRIBUTO SCELTO (NELL'es. DI OUTLOOK I POSSIBILI VALORI SONO SUNNY / RAINY):

- GLI ESEMPI VENGONO SUDDIVISI IN SOTTOGRUPPI IN BASE AL VALORE.
- DTL VIENE CHIAMATA RICORSIVAMENTE PER COSTRUIRE L'ALBERO DI CIASUN SOTTOGRUPPO, BEST VIENE RIMOSSE DAGLI ATTRIBUTI DISPONIBILI.
- IL SOTTOALBERO VIENE COLLEGATO AL NODO ATTUALE (BEST) DELL'ALBERO.

6 RITORNA L'ALBERO

ESEMPIO

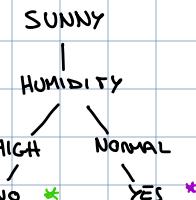
Outlook	Temperature	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No



DIVISIONE IN BASE AL VALORE DI OUTLOOK

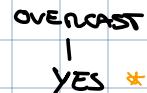
- Se Outlook = Sunny:

Temperature	Humidity	Windy	Play
Hot	High	False	No *
Hot	High	True	No *
Mild	High	False	No *
Cool	Normal	False	Yes *
Mild	Normal	True	Yes *



- Se Outlook = Overcast:

Temperature	Humidity	Windy	Play
Hot	High	False	Yes *
Cool	Normal	True	Yes *
Mild	High	True	Yes *
Hot	Normal	False	Yes *

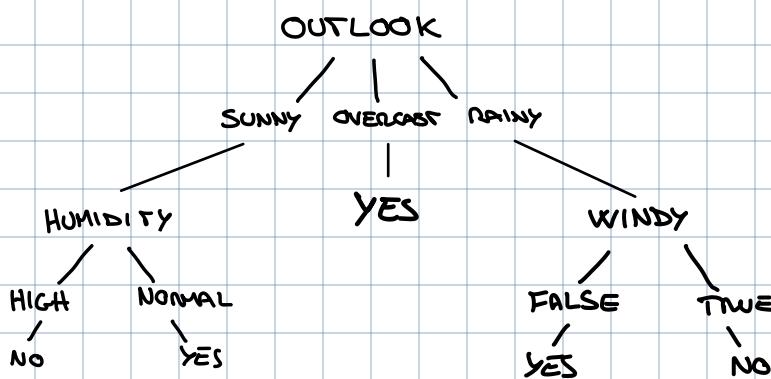


- Se Outlook = Rainy:

Temperature	Humidity	Windy	Play
Mild	High	False	Yes *
Cool	Normal	False	Yes *
Cool	Normal	True	No *
Mild	Normal	False	Yes *
Mild	High	True	No *



RICOMPONIAMO L'ALBERO FINALE



SCELTA DELL' ATTRIBUTO

ENTROPIA

L'ENTROPIA MISURA LA QUANTITÀ DI INCERTEZZA IN UN SET DI DATI.

DEFINITA COME: $I(P(v_1), \dots, P(v_m)) = \sum_{i=1}^m -P(v_i) \cdot \log_2 P(v_i)$

\downarrow PROBABILITÀ CHE IL VALORE v_i SI VERIFICA

ESEMPIO, PER UN SET DI DATI CON P ESEMPI POS & M ESEMPI NEG.

$$I(P, m) = -\frac{P}{P+m} \cdot \log_2 \left(\frac{P}{P+m} \right) - \frac{m}{P+m} \cdot \log_2 \left(\frac{m}{P+m} \right)$$

REMAINDER

UN ATTRIBUTO SCELTO A DIVIDE IL SET E IN SOTTOGRUPPI E_1, \dots, E_v IN BASE AI VALORI v CHE L'ATT. PUÒ ASSUMERE.

$$\text{REMAINDER}(A) = \sum_{i=1}^v \frac{E_i}{E} I(P_i, m_i)$$

\downarrow ENTROPIA

$E_i = *$ ESEMPI NEL SOTTOGRUPPO E_i
 $E = *$ ESEMPI GENERALI NEL SET

GUADAGNO INFORMATIVO (IG)

RIDUZIONE DELL'ENTROPIA, SI OTTIENE CON:

$$IG(A) = I(P, m) - \text{REMAINDER}(A)$$

SCELTA

SCEGLIAMO L'ATTRIBUTO CON IG MAGGIORE.

Con il guadagno informativo (IG), stai calcolando quanto l'incertezza (entropia) del set di dati si riduce quando scegli un attributo specifico per suddividere i dati. È una misura della qualità di un attributo come criterio di divisione in un albero decisionale.

In altre parole:

- L'entropia iniziale misura quanto è incerta (disordinata) la classificazione del set di dati prima di prendere una decisione basata su un attributo.
- Quando scegli un attributo e dividi i dati, la nuova incertezza (resto dell'informazione, $\text{Remainder}(A)$) riflette quanto rimane di questa incertezza dopo la suddivisione.
- Il guadagno informativo è la differenza tra l'incertezza iniziale e quella rimanente:

$$IG(A) = I(p, n) - \text{Remainder}(A)$$

Interpretazione pratica

1. Se $IG(A)$ è grande:
 - L'attributo A è un buon candidato per dividere i dati perché riduce significativamente l'incertezza.
 - Significa che, conoscendo il valore di A , hai più probabilità di classificare correttamente i dati.
2. Se $IG(A)$ è piccolo:
 - L'attributo A non fornisce molta informazione utile per la classificazione.
 - Anche conoscendo il valore di A , l'incertezza rimane alta.

ESEMPIO

Exam	Friends	Weather	Activity
yes	yes	sunny	study
no	yes	sunny	picnic
yes	no	rain	study
yes	yes	rain	study
no	yes	rain	play
no	no	rain	play

IG → MISURA QUANTO BENE UN ATTRIBUTO SEPARA I DATI IN BASE ALLE CLASSI DI DESTINAZIONE.

$$\text{ENTROPIA} \rightarrow - \sum_{i=1}^m p_i \log_2(p_i)$$

↓ PROBABILITÀ CHE L'ATTRIBUTO SI VERIFichi

ENTROPIA INIZIALE

CALCOLIAMO QUANTE VOLTE SI VERIFICANO LE CLASSI:

- $P(\text{STUDY}) = 3/6$
- $P(\text{PICNIC}) = 1/6$
- $P(\text{PLAY}) = 2/6$

$$\xrightarrow{\text{ENTROPIA}} -\frac{3}{6} \cdot \log_2\left(\frac{3}{6}\right) - \frac{1}{6} \cdot \log_2\left(\frac{1}{6}\right) - \frac{2}{6} \cdot \log_2\left(\frac{2}{6}\right) \approx 1.46$$

INFORMATION GAIN

$$\text{IG (ATTRIBUTO)} = \text{ENTROPIA INIZIALE} - \text{ENTROPIA (ATTRIBUTO)}$$

CALCOLO ENTROPIA ATTRIBUTO

IDENTIFICO I POSSIBILI VALORI CHE PUÓ ASSUMERE L'ATTRIBUTO

↳ COSTRUISCO IL SOTTOINSIEME PER OGNI VALORE

↳ CALCOLO L'ENTROPIA PER QUEL SOTTOINSIEME

↳ CALCOLO IL PESO MEDIO DELL'ENTROPIA CON:

$$\sum_{i=1}^k \frac{|S_i|}{|S|} \cdot \text{ENTROPIA}(S_i)$$

$|S_i|$ = DIMENSIONE DEL SOTTOINSIEME i

$|S|$ = DIMENSIONE TOTALE DI TUTTI I VALORI DELL'ATTRIBUTO

ENTROPIA(S) = ENTROPIA DEL SOTTOINSIEME S ;

CALCOLO ENTROPIA ATTRIBUTO EXAM

L' ATTRIBUTO EXAM SI SUDDIVIDE IN:

- YES
- NO

SOTTOINSIEME DI YES = { STUDY, STUDY, STUDY }
 SOTTOINSIEME DI NO = { PICNIC, PLAY, PLAY }

ENTROPIA DI YES:

$$-\frac{3}{3} \cdot \log_2\left(\frac{3}{3}\right) = 0$$

ENTROPIA DI NO:

- PICNIC = $\frac{1}{3}$
- PLAY = $\frac{2}{3}$ $\rightarrow -\frac{1}{3} \cdot \log_2\left(\frac{1}{3}\right) - \frac{2}{3} \cdot \log_2\left(\frac{2}{3}\right) \approx 0.918$

PESO MEDIO:

$$\text{ENTROPIA (Exam)} = \frac{3}{6} \cdot 0 + \frac{3}{6} \cdot (0.918) = \underline{\underline{0.459}}$$

CALCOLO IG PER EXAM:

$$\text{IG(Exam)} = 1.46 - 0.459 = \underline{\underline{1.001}}$$

IG PER GLI ALTRI ATTRIBUTI

$$\begin{aligned} \text{IG}(D, \text{Exam}) &\sim 1 & \xrightarrow{\text{MIGLIORE, LO SCELGO E LO TOLGO}} & \times \text{LE} \\ \text{IG}(D, \text{Friends}) &\sim 0.13 & & \text{ENTROPIE SUCCESSIVE} \\ \text{IG}(D, \text{Weather}) &\sim 0.46 & & \end{aligned}$$

IG SUCCESSIVI

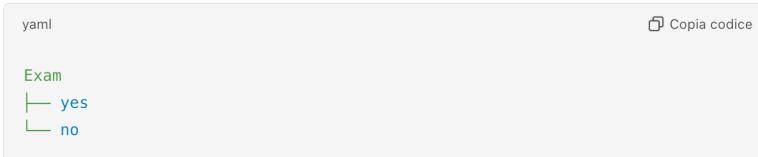
$$\begin{aligned} \text{IG}(D\text{-No-Exam, Friends}) &\sim 0.25 \\ \text{IG}(D\text{-No-Exam, Weather}) &\sim 0.92 & \xrightarrow{\text{MIGLIORE, LO SCELGO}} & \end{aligned}$$

ALBERO DI DECISIONE



COSTRUZIONE DEI RAMI DELL' ALBERO

- Dopo aver calcolato l'*IG* per tutti gli attributi, scegli quello con il massimo *IG*. Nell'esempio, se l'attributo `Exam` ha il massimo *IG*, diventa il **nodo radice** dell'albero.
- Aggiungi i rami per ciascun valore possibile dell'attributo scelto. Ad esempio, per `Exam`, i valori sono `yes` e `no`. Quindi il nodo radice sarà:



Passo 2: Analizza i sottoinsiemi

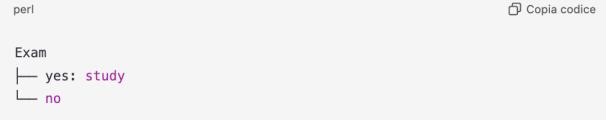
Per ciascun ramo (valore dell'attributo `Exam`), analizza il sottoinsieme corrispondente del dataset:

1. Per `Exam = yes`:

- Considera solo le righe dove `Exam = yes`.
- Osserva i valori della variabile target (`Activity`) in questo sottoinsieme:
`{study, study, study}`

Poiché tutte le righe hanno la stessa classe (`study`), questo nodo è **puro**.

Il ramo `Exam = yes` termina qui:



2. Per `Exam = no`:

- Considera solo le righe dove `Exam = no`.
- Osserva i valori della variabile target (`Activity`) in questo sottoinsieme:
`{picnic, play, play}`

Qui ci sono due classi (`picnic` e `play`), quindi questo **nodo non è puro**. Dobbiamo continuare a dividere.

WORDNET & FRAMENET

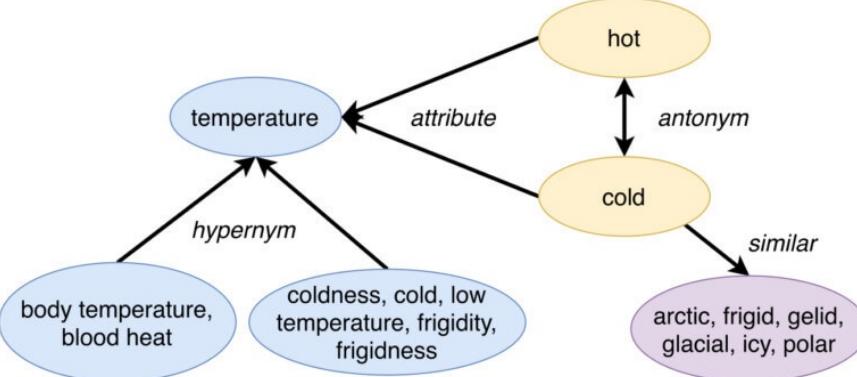
WORDNET

È UNA RISORSA LESSICALE PROGETTATA PER LA LINGUISTICA COMPUTAZIONALE E IL TRATTAMENTO DEL LINGUAGGIO NATURALE. È UNA RETE DI SINONIMI CHIAMATI **SYNSETS** CHE RAGGRUPPANO PAROLE CON SIGNIFICATI SIMILI.

WORDNET STRUTTURA

STRUTTURA A NODI & ARCHI DOVE:

- NODI (SYNSETS)** COMPOSTI DA INSIEMI DI PAROLE CON SIGNIFICATO SIMILE, AD ESEMPIO "AUTO, AUTOMOBILE, CAR" RAPPRESENTA IL CONCETTO DI AUTOMOBILE.
- ARCHI**, RAPPRESENTATI DA RELAZIONI SEMANTICHE TRA CONCETTI, TRA CUI:
 - IPERONIMIA**: RELAZIONE CONCETTO GENERALE - SPECIFICO. ES. "VEICHLE" — "CAR"
 - IPONIMIA**: RELAZIONE INVERSA, SPECIFICO - CONCETTO GENERALE ES. "CAR" — "VEICHLE"
 - MERONIMIA**: RELAZIONE DI PARTE - TUTTO. ES. "WHEEL" — "CAR"
 - ANTONOMIA**: RELAZ. TRA PAROLE CON SIGNIFICATO OPPOSTO. ES. "HOT" & "COLD"
 - TROPONIMIA**: RELAZ. CHE DESCRIVE UN MODO DI FAR UN'AZIONE. ES. "WALK" — "MOVE"



WORDNET UTILIZZO

USATO IN MOLTE APPLICAZIONI DI NLP, TRA CUI:

- DISAMBIGUAZIONE SEMANTICA: DETERMINARE IL SIGNIFICATO DI UNA PAROLA IN BASE AL CONTESTO
- ANALISI DEL SENTIMENT: ANALIZZARE IL SENTIMENT USANDO LE RELAZIONI TRA PAROLE.
- MACHINE TRANSLATION: TRADUZIONE TRA LINGUE
- GENERAZIONE AUTOMATICA DEL TESTO: CREAZIONI DI FRASI COERENTI

FRAME NET

È UN VASTO DATABASE CHE SI BASA SULLA TEORIA DEI FRAME SEMANTICI. QUESTA TEORIA È UNO DEGLI APPROCCI PIÙ AVANZATI PER RAPPRESENTARE IL SIGNIFICATO DEL LINGUAGGIO NATURALE IN TERMINI DI EVENTI, SITUAZIONI E RELAZIONI CON I PARTECIPANTI COINVOLTI.

FRAME NET STRUTTURA

UN FRAME SEMANTICO È UNA STRUTTURA CONCETTUALE CHE DESCRIVE UNA "SCENA", EVENTO, UNA SITUAZIONI CON I SUOI PARTECIPANTI. OGNI FRAME INCLUDE:

- **CORE ROLES**: DESCRIVONO LE ENTITÀ PRINCIPALI COINVOLTE NELLO SCENARIO (ESSENZIALI X IL SIGNIFICATO)
- **NON-CORE ROLES**: FORNISCONO INFORMAZIONI AGGIUNTIVE SUL CONTESTO (DESCRITTIVE)
- **TRIGGER LESSICALI (LEXICAL UNITS/LUs)**: PAROLE CHE EVOCANO O RICHIAMANO UN PARTICOLARE FRAME. QUANDO UNA LU VIENE IDENTIFICATA IN UNA FRASE, QUESTA PUÒ ESSERE ASSOCIATA A DEI FRAMI SPECIFICI, PER OGNI FRAME POSSONO ESSERCI PIÙ LUs ASSOCIAZI, ALLO STESSO TEMPO UN LU PUÒ ESSERE PRESENTE IN PIÙ FRAMES, AD ESEMPIO QUANDO UNA PAROLA HA PIÙ SENSI.

AD ESEMPIO LE LUs CHE EVOCANO IL FRAME **LAMENTARSI** INCUDONO I VERBI: **LAMENTARSI**, **BRONTOLARNE**, ECC. ECC.

I FRAME SONO ASSOCIATI CON UNA FRASE DI ESEMPIO E GLI ELEMENTI SONO MARCATI ALL'INTERNO DELLA FRASE.

Cutting

Definition: An [Agent] cuts an [Item] into [Pieces] using an [Instrument] (which may or may not be expressed).

Core frame elements:

Agent	The [Agent] is the person cutting the [Item] into [Pieces].
Item	The item which is being cut into [Pieces].
Pieces	The [Pieces] are the parts of the original [Item] which are the result of the slicing.

Non-core frame elements:

Instrument	The [Instrument] with which the [Item] is being cut into [Pieces].
Manner	[Manner] in which the [Item] is being cut into [Pieces].
Result	The [Result] of the [Item] being sliced into [Pieces]. (extrathematic)
In addition:	Means, Purpose, Place, Time

Lexical units: *carve, chop, cube, cut, dice, fillet, mince, pare, slice*

→ FRAME DELLO SCENARIO "CUTTING"

ESEMPIO

UN ESEMPIO DI SCENARIO CODIFICATO È QUELLO DI "COMMERCE SCENARIO" IN INGLESE UNO SCEN. DI COMMERCIO.

"COMMERCE SCENARIO"

IN INGLESE

CHE RAPPRESENTA

LUs:

(EN) buyer, commerce, cost, goods, price, purchaser, retailer, seller, vendor
compratore, commercio, costo, beni, prezzo, acquirente, venditore, rivenditore

RUOLI SEMANTICI IDENTIFICATI PER IL FRAME:

- **Buyer**: rappresenta il **compratore** che possiede il denaro per acquistare i beni.
- **Goods**: rappresenta i **beni** che vengono venduti
- **Money**: rappresenta il **denaro** utilizzato nella transazione
- **Seller**: rappresenta il **venditore** che possiede i beni da vendere

FRASE DI ESEMPIO CON LE RELATIVE PARTI ANNOTATE (RICONOSCUTE):

(EN) **Mario** bought **a carpet** from **the seller** for **1000 euros**.
Mario ha acquistato **dal negoziante** **un tappeto** per **1000 euro**.

Ruoli Core

Questi sono essenziali per il significato centrale del frame e definiscono i partecipanti principali nel contesto del commercio:

- **Buyer (Compratore)**: "Mario" — colui che acquista i beni.
- **Goods (Beni)**: "a carpet" — il prodotto oggetto della transazione.
- **Seller (Venditore)**: "from the seller" — colui che vende i beni.

Ruoli Non-Core

Questi aggiungono informazioni contestuali, ma non sono fondamentali per definire l'evento centrale del commercio:

- **Money (Denaro)**: "for 1000 euros" — la somma utilizzata nella transazione.

FRAME NET RELAZIONI

I FRAME SONO ANCHE RELAZIONATI TRA LORO ATTRAVERSO TIPI DI RELAZIONI, TRA CUI:

- **Ereditarietà (Inheritance)**: Questa relazione indica che un frame figlio è una sottocategoria di un frame genitore. Il frame figlio eredita gli elementi del frame (FE) dal genitore, con possibili specificazioni aggiuntive. Ad esempio, il frame "Revenge" eredita dal frame "Rewards_and_punishments", implicando che la vendetta è un tipo specifico di ricompensa o punizione.
- **Utilizzo (Using)**: In questa relazione, un frame presuppone un altro frame come contesto di base. Ad esempio, il frame "Speed" utilizza il frame "Motion", poiché il concetto di velocità implica un movimento sottostante. Non è necessario che tutti gli elementi del frame genitore siano mappati nel frame figlio.

- **Sottoframe (Subframe)**: Un frame complesso può essere suddiviso in sottoeventi rappresentati da subframe. Ad esempio, il frame "Criminal_process" comprende subframe come "Arrest", "Arraignment", "Trial" e "Sentencing", che rappresentano le diverse fasi del processo penale.
- **Prospettiva su (Perspective_on)**: Questa relazione indica che un frame offre una particolare prospettiva su un frame non prospettivizzato. Ad esempio, i frame "Hiring" e "Get_a_job" forniscono prospettive diverse sul frame "Employment_start", rispettivamente dal punto di vista del datore di lavoro e del dipendente.

Esecuzione Intuitiva (senza calcoli complessi)

Per stimare intuitivamente:

1. Osserva la distribuzione dei target per ciascun valore dell'attributo:
 - Se un valore dell'attributo contiene esclusivamente una classe (es., tutte "Possibile" o tutte "Ottima"), allora quel valore contribuisce molto a ridurre l'entropia.
 - Se i valori dell'attributo hanno una distribuzione mista, l'attributo riduce poco l'entropia.
2. Stima il peso di ciascun valore dell'attributo:
 - Valori con molti record hanno più impatto sull'entropia condizionata rispetto a valori con pochi record.

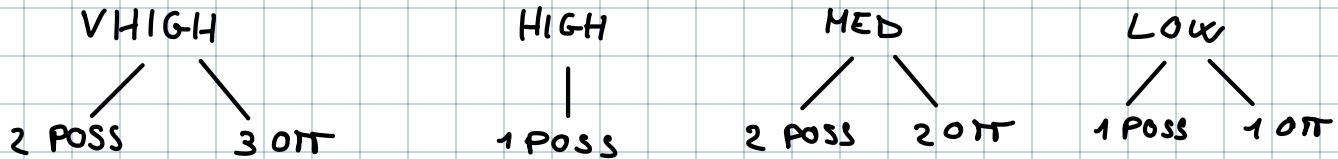
Esempio: "Prezzo" e "Porte"

1. "Porte":
 - "2" ha solo "Possibile" → contribuisce molto a ridurre l'entropia.
 - "oltre5" ha solo "Ottima" → anche questo contribuisce molto.
 - "3" e "4" hanno distribuzioni miste → meno impatto.
2. "Prezzo":
 - Ogni valore ("vhigh", "med", ecc.) ha distribuzioni miste → riduce meno l'entropia rispetto a "Porte".

Conclusione: "Porte" è intuitivamente migliore perché separa le classi con maggiore chiarezza.

Prezzo	Porte	Classe Target
vhigh	2	Possibile
vhigh	3	Ottima
vhigh	2	Possibile
vhigh	3	Ottima
vhigh	4	Ottima
high	2	Possibile
med	2	Possibile
med	oltre5	Ottima
med	2	Possibile
med	oltre5	Ottima
low	3	Possibile
low	4	Ottima

PREZZO



PORTE

